



Automation Soriana Cobros v1.0

Pipeline de cruce CPA Vision y
Validación de Condiciones

Documento técnico: arquitectura, módulos,
librerías y escalabilidad

Realizado por: Oscar Alexis Pineda Henao

Qué es Automation-Cobros

Descripción técnica

Pipeline en Python que automatiza la auditoría de condiciones: ingiere compras de SAP (SQL Server) y facturas electrónicas descargadas de CPA Vision (dataset Parquet), las cruza por factura y código de barra, recalcula el costo auditado y genera la Validación de Condiciones. Es un proceso reproducible, versionado y en evolución, diseñado para escalar a proveedores de decenas de millones de renglones y seguir sumando proveedores.

Python 3.13

Lenguaje base

Stack completo

~14

Módulos

automation_cobros/

Parquet

Datos de CPA Vision

Almacenamiento en disco

CLI + GUI

Formas de uso

Terminal / customtkinter



Arquitectura: pipeline de una acción

El sistema tiene dos etapas: (1) SQL → Excel y (2) scraping de CPA Vision. El pipeline las une y encadena cuatro pasos en memoria, sin intervención manual.

fetch → cruce → recálculo → export



Orquestado por pipeline.py (normal) o pipeline_streaming.py (por trimestre, gigantes).

Paquete automation_cobros/

- database.py — SQL Server (F_COMPRAS); une las dos bases por año
- cruce_cpa.py — cruce facturas↔compras (DuckDB + pandas)
- calculations.py — costo auditado, impuestos y agregación
- excel_exporter.py — escribe el Compras (XlsxWriter, streaming)
- validation_exporter.py — Validación (Consolidado + Detalle)
- pipeline.py — orquesta el flujo (con variante por trimestre)
- cpa_vision.py — scraping del portal CPA Vision (Playwright)
- cpa_parquet.py — convierte el ZIP descargado a Parquet
- app.py / ui.py — GUI en customtkinter (estilo PRGX)


Librerías principales de Python

- **pandas** — transformación y cálculo del costo auditado
- **DuckDB + PyArrow** — leen el dataset Parquet sin cargarlo en RAM
- **pyodbc** — conexión a SQL Server (F_COMPRAS)
- **XlsxWriter** — escritura en streaming, sin límite de renglones
- **openpyxl** — lectura y relectura de los Compras
- **Playwright** — descarga automatizada de CPA Vision (msedge)
- **customtkinter** — interfaz gráfica de escritorio

El cruce: DuckDB + pandas

El cruce llena las columnas EDI del Compras con datos de la factura electrónica: DuckDB lee del Parquet solo lo que puede cruzar, pandas hace el match e imputa, y nunca sobrescribe un dato que ya venía.

Filtrar en DuckDB → imputar en pandas



Optimizaciones para no agotar la RAM

Un proveedor de 11 M+ de renglones no cabe en 24 GB (Out of memory): No cargarlo de golpe

Procesar por partes (trimestres)



pico de RAM acotado

Traer solo lo que cruza



9 GB → 2.7 GB

Escribir el Excel en tandas



millones de filas

Verificación

Cada optimización se comparó contra el proceso normal en un proveedor chico y la salida es **idéntica**: se reduce la memoria usada, no la exactitud del cálculo.

De la fuente al entregable

- **SQL Server** — F_COMPRAS en dos bases por año (2020–2024 y 2025)
- **CPA Vision** — Playwright descarga el ZIP de facturas del portal
- **Parquet (Hive)** — particionado por `rfc/year/request_id` (DuckDB)
- **Excel** — Compras y Validación con XlsxWriter (varias hojas si superan 1 M)
- **Entregables** — quedan en la carpeta de auditores; no en el proyecto

Subcomandos de `main.py`

- `cpa-salida` — proveedor completo (compras, cruce, recálculo, validación)
- `cpa-validacion-grande` — solo Validación, por trimestre (gigantes)
- `cpa-compras-grande` — solo Compras, por trimestre o mes, resumible
- `cpa-batch-vendors` — descarga masiva de CPA Vision desde un Excel de RFC
- `gui` — interfaz gráfica (customtkinter), lanza el flujo sin terminal

Principales dificultades técnicas

Los retos no fueron del cálculo en sí, sino de la escala y del entorno de ejecución.

- Proveedores de 10–12 millones de renglones que no caben en 24 GB de RAM (Out of memory).
- Facturas masivas: pocos códigos de barra que hacen match con millones de conceptos.
- ~30% de renglones sin nota de entrada (no auditables a nivel folio).
- Compras en dos bases por año que hay que unir sin duplicar renglones.
- Máquina de trabajo con baja capacidad de procesamiento.

Lectura técnica

La arquitectura por intervalos, el filtrado de la factura electrónica y la escritura en streaming permiten correr proveedores enormes en hardware modesto, de forma reproducible y resumible.

Impacto: automatización frente a trabajo manual

Los 6 proveedores prioritarios ejecutados de punta a punta (descarga de CPA Vision, cruce y Validación de Condiciones), en comparativa con el tiempo promedio que tomaría hacerlo un auditor de forma manual.

Proveedor	Registros	Automatización	Auditor manual
Arca Continental	11.5 M	~7 h	3 semanas
Pepsico	10.1 M	~6 h	≈ 2,6 semanas
Marcas Nestlé	1.30 M	~1,5 h	≈ 1,7 días
Empacadora Celaya	1.24 M	~1 h	≈ 1,6 días
Selecta del Campo	58,558	~15 min	≈ 0,6 h
3M México (2025)	25,000	~8 min	≈ 0,3 h
Totales	≈ 24.2 M	≈ 16 h	≈ 6,3 semanas

24 M de registros procesados en **~16 horas** de automatización, frente a **~6 semanas** de trabajo manual.



Escalabilidad e integración con Audit Services

Contexto

AuditTools (Access + Visual Basic) es la herramienta estándar de PRGX que extrae las compras de SQL Server. La meta: integrar Automation-Cobros con esa plataforma.

- **Interoperabilidad:** correr los scripts de Python (Playwright, pandas, DuckDB) desde Visual Basic.
- **Motor de datos portable:** de DuckDB + Parquet a SQL Server o PostgreSQL sin reescribir la lógica.
- **Histórico persistente:** guardar compras y recálculos en base de datos para trazabilidad.
- **Sincronización de entornos:** versionado, despliegue y parámetros configurables por plataforma.



Estado actual y próximos pasos

Estado

El pipeline está operativo y validado técnicamente sobre un conjunto piloto de proveedores. Es un proyecto en evolución: la meta es escalarlo al universo de proveedores pendientes por trabajar e integrarlo al estándar de Audit Services.

- Definir con Audit Services la integración con AuditTools (Python desde Visual Basic).
- Persistir histórico de compras y de los recálculos del auditor para trazabilidad.
- Seguir descargando CPA Vision de los proveedores prioritarios pendientes.
- Cerrar con negocio la regla de clasificación de diferencias antes de reportar montos.
- Evaluar la portabilidad del motor de datos (SQL Server / PostgreSQL).
- Conectar la GUI con las dos etapas y mantener la documentación al día.